Arquiteto de Soluções IA Expert

Relatório de Entrega do Desafio Final

ChatBot no Google Colab

Aluno: Fabiano Correa da Silveira

Sumário

Desenvolvimento da Solução do Desafio Final 3
1. Evidência da conta Google 3
2. Evidência do acesso ao Google Colab 3
3. Evidências da importação do script do ChatBot no Google Colab 4
4. Evidências da execução do ChatBot no Google Colab 5
5. Evidências do teste do ChatBot sem modificação de parâmetros 6
Resultado Obtido 6
6. Evidências do teste do ChatBot com modificação de parâmetros 7
Resultado Obtido 7
Conclusão 8

Desenvolvimento da Solução do Desafio Final

1. Evidência da conta Google

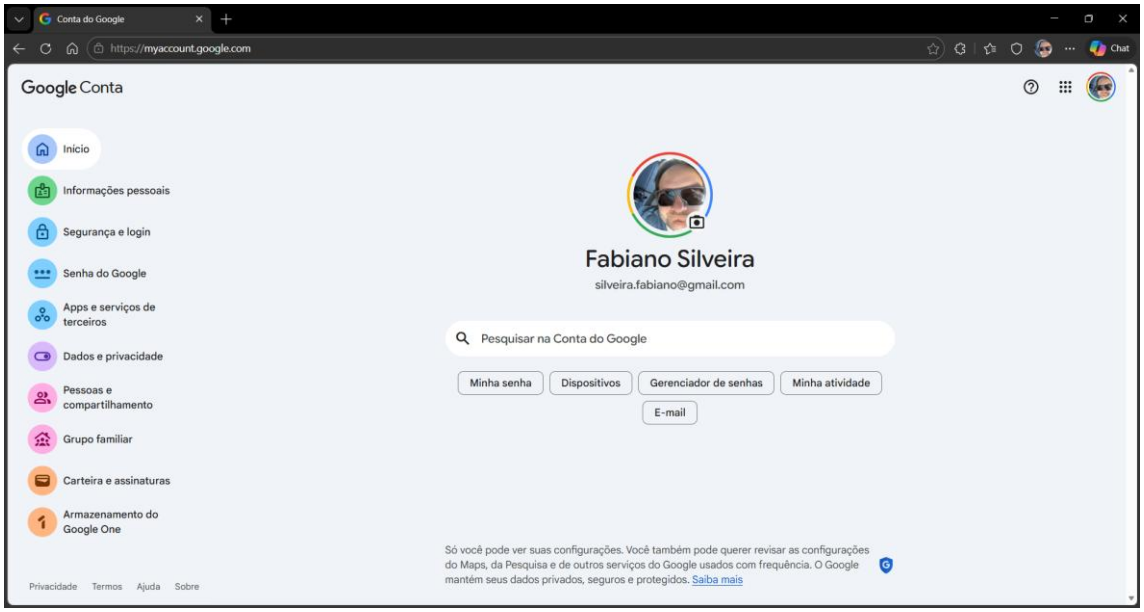

2. Evidência do acesso ao Google Colab

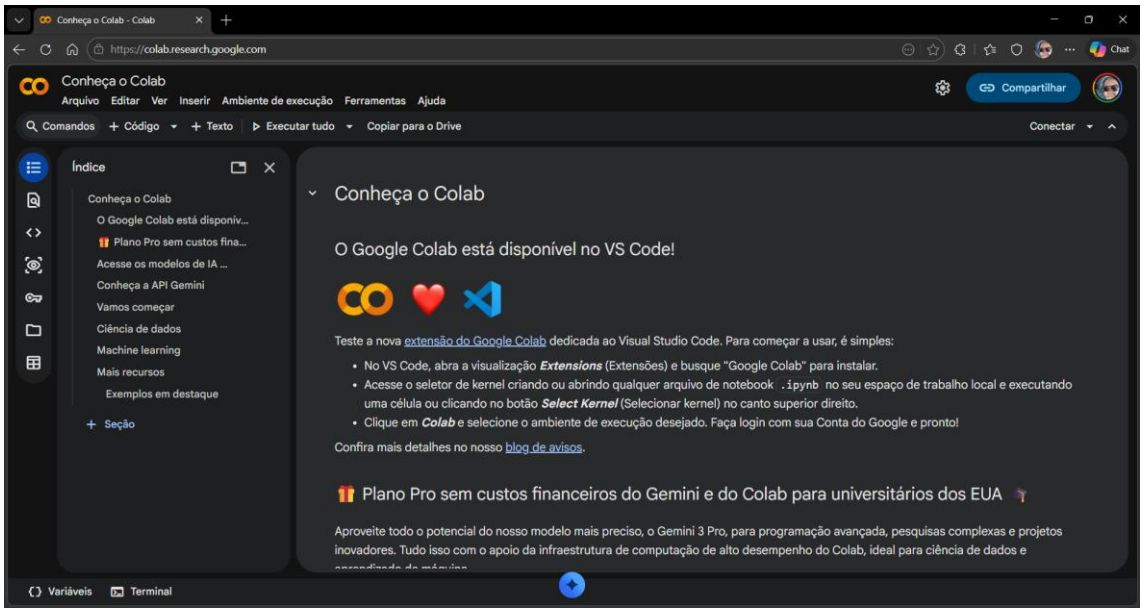

3. Evidências da importação do script do ChatBot no Google Colab

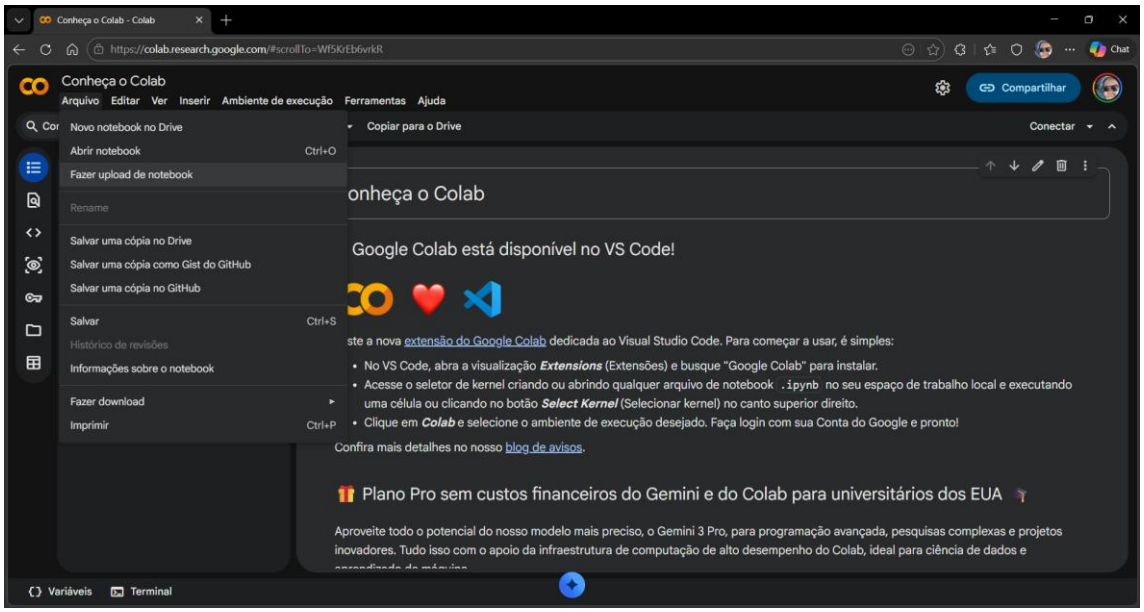

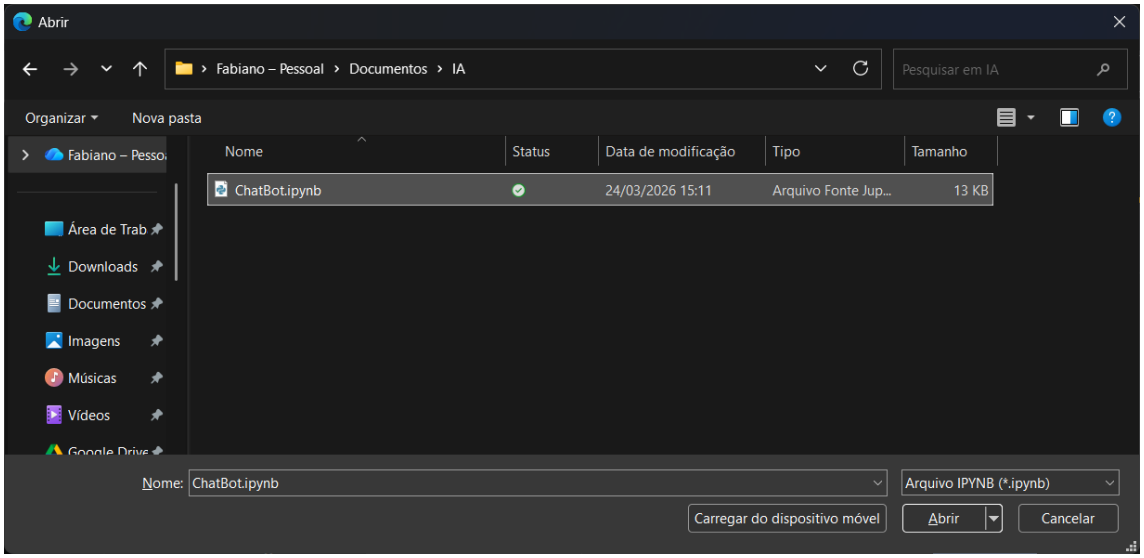

4. Evidências da execução do ChatBot no Google Colab

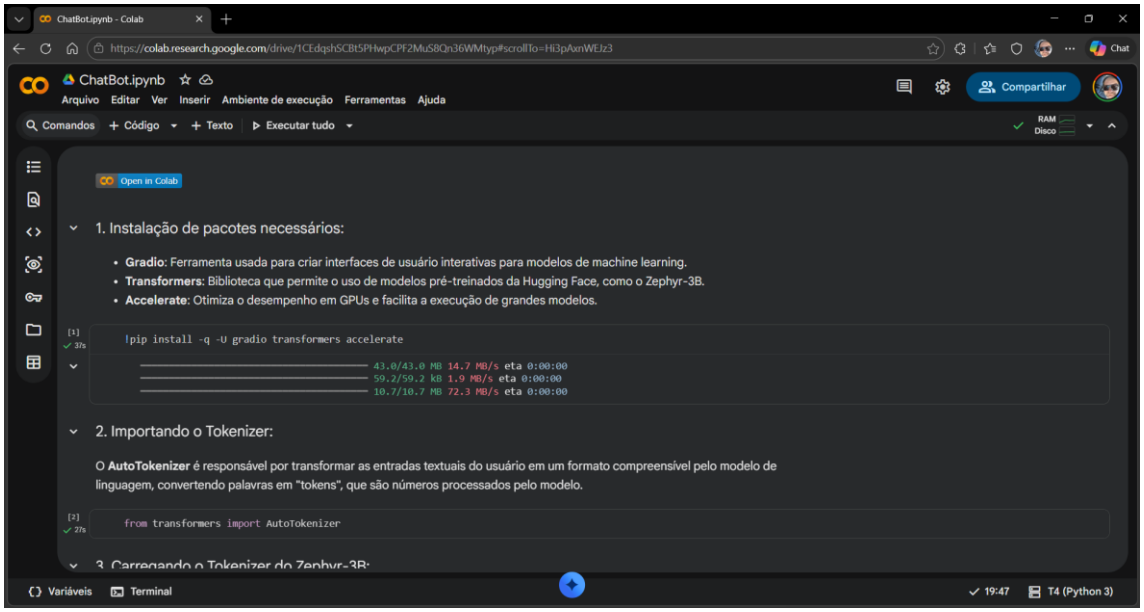

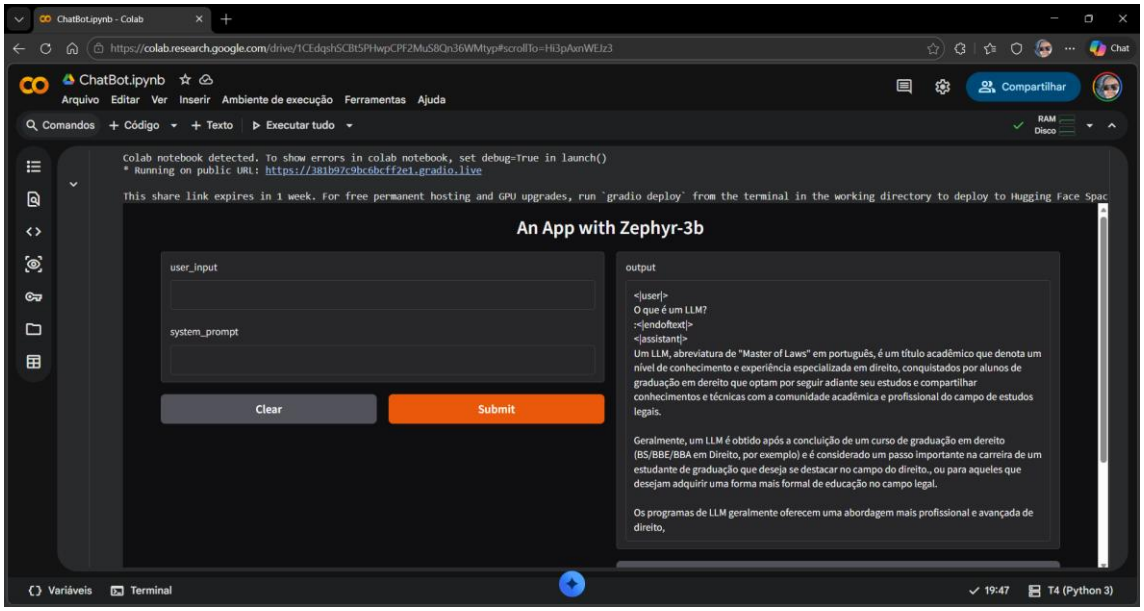

5. Evidências do teste do ChatBot sem modificação de parâmetros

Parâmetros considerados na execução do teste:

- Temperature = 0.8
- Max_new_tokens = 250
- Do_sample = False
- System_prompt = Vazio

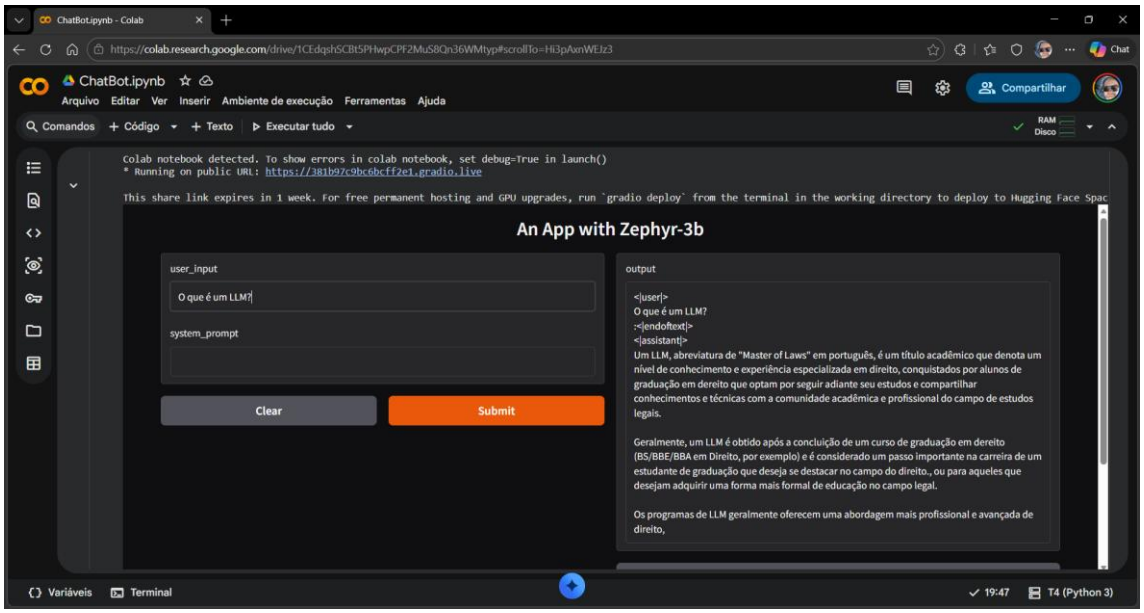

Resultado Obtido

O output apresentou como resposta uma explicação para a sigla LLM que não tem qualquer relação com IA. A resposta foi curta e o tempo de resposta foi rápido.

6. Evidências do teste do ChatBot com modificação de parâmetros

Parâmetros considerados na execução do teste:

- Temperature = 0.1
- Max_new_tokens = 500
- Do_sample = True
- System_prompt = Preenchido

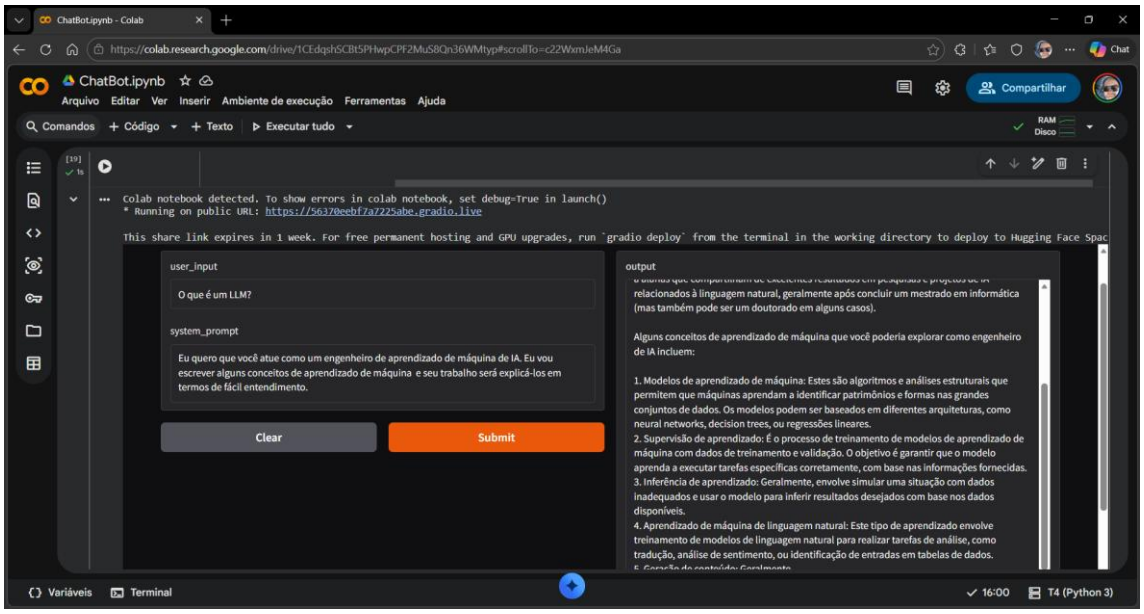

Resultado Obtido

O output apresentou uma resposta muito mais próxima do contexto solicitado no prompt. A resposta foi muito mais rica em conteúdo relevante e o tempo de resposta também aumentou na mesma proporção.

Conclusão

A análise dos resultados obtidos na execução do ChatBot via Google Colab evidenciou que a eficácia de uma solução de Inteligência Artificial Generativa vai além da escolha do modelo ou do aprendizado de máquina. Os testes demonstraram a importância crítica da calibração de parâmetros de inferência. A manipulação de variáveis como a temperatura e o system prompt provou-se fundamental para mitigar alucinações do modelo e alinhar o comportamento do assistente ao contexto desejado. Sob a ótica da arquitetura de soluções, este nível de controle é indispensável: ajustar parâmetros como o limite de tokens não apenas refina a relevância da resposta, mas também permite arquitetar soluções mais previsíveis, escaláveis e otimizadas em termos de latência e custos computacionais para futuras aplicações profissionais.